ChatGPT

China A-Share Market Microstructure Prediction 竞赛信息整理

比赛内容与目的

- **背景与目标**：该比赛由 LXJ_Competitions 主办，旨在利用聚合后的 **Level 2 深度盘口数据** 构建高频市场模型。参与者需要预测中国 A 股股票的微观结构收益（短期绝对收益），这与传统日线价格预测不同，挑战重点是从 **原始逐笔行情数据中提取信号** [1]。
- **数据与任务**：
- **数据来源**：主办方提供来自 500 只 A 股的数百日历史高频数据，数据分为 `train.parquet` 和 `test.parquet` 两部分 [2]。两者按 `stockid` 分区，便于顺序读取。
- **特征与标签**：数据集中包括：
  - `stockid`（股票编号，0–499），`dateid`（交易日编号，从 0 开始），`timeid`（当天 0–238 的时间索引），`exchangeid`（交易所标识）以及 **384 个匿名微观结构特征** `f0` – `f383` [2]。
  - `LabelA` 为评分标签（需要预测的目标），`LabelB`、`LabelC` 为辅助标签 [2]。
- **挑战内容**：从海量高频特征中提取具有预测力的信号，准确预测分钟级收益，同时要适应市场制度和波动的突变，并在高维特征空间中提取信号而不被噪声淹没 [3]。
- **竞赛意义**：主办方指出该竞赛模拟了量化对冲基金和做市商常见的难题，参赛者将接触现实世界的高质量交易数据，这些数据通常对公众不可见 [3]。

官方要求、数据格式与评测规则

提交流程与文件格式

- **预测输出文件**：参赛者需对测试集中的每个 ID 预测未来收益并生成 CSV 文件。
- **文件格式**：讨论区经确认，CSV 首行表头必须是 **`Uid,prediction`**，其中 `Uid` 是以管道符 `|` 连接的 `stockid|dateid|timeid` 组合键，`prediction` 为预测值 [4]。示例：

```
Uid,prediction
0|0|0,0.0001
0|0|1,0.0002
…
```

- **重要注意事项**：[4]
- **评测集最后 10 个 timeid（229–238）的预测** 不计入评分，但仍必须提交完整预测文件。
- 在预测某个 `timeid` 时，只能使用当日及其之前的 `dateid` 和 `timeid` 数据；禁止使用未来信息或向前看数据（即不能利用未来时间的数据） [4]。
- **提交代码要求**：为保证 reproducibility，团队必须提交用于生成预测的源代码，主办方会审查代码，若发现使用未来信息或违规数据将取消资格 [4]。

评测指标与评分

- **指标**：比赛采用 **R 平方 (R^2) 面板指标**，计算公式为 $1 - \Sigma_i (y_i - \hat{y}_i)^2 / \Sigma_i (y_i - \bar{y})^2$ [3]。主持人在讨论中明确该指标是 **整体面板 R^2**，即在所有时间和股票样本上一次性计算，而不是先按时间截面计算再平均 [5]。

- **评分侧重点**：比赛关注在高频交易中捕捉 **市场异动** 的能力，评测方式鼓励模型在高波动时段准确预测，即使低波动资产的误差影响较小 [3]。

竞赛规则与限制

- **账户与团队**：每位参赛者只能使用一个 Kaggle 账户，团队最多 3 人，可以合并团队但合并后提交数不得超过队伍规模 × 已运行天数 [6]。
- **提交限制**：每天最多 5 次提交，可以在截止前选择 **2 份最终提交** 参与排名 [6]。
- **比赛时间线**：条目页面上标出比赛开始和结束日期；当前为私人比赛，距离结束约一个月，具体的条目时间（报名截止、最终提交截止等）请以概览页时间线为准 [1]。
- **外部数据与工具**：根据 Kaggle 通用规则，除非明示允许，否则禁止使用与官方数据不同的其他数据；不可将模型预测过程中的代码或数据泄露给队伍外人员 [6]。
- **获奖者义务**：潜在获奖者必须提供产生获胜提交的代码和文档；若代码涉及商用软件，需告知主办方以便他们在不额外付费的情况下复现结果 [7]。

讨论区有价值的信息梳理

话题/来源	关键信息	参考
使用未来信息警告（Pinned Topic）	主办方发现有参赛者可能在预测中使用了未来信息获得极高分数，强调会审查获胜提交的源代码，若发现使用未来数据将取消其最终排名，呼吁参赛者撤回此类提交 [8]。	讨论帖 “Submissions using future information”
为什么不评测最后 10 个 timeid?	主办方解释由于比赛不涉及隔夜收益，最后 10 个 timeid 波动较小并且受 T+1 交易制度影响，预测价值较低，因此不计入评分，但提交文件仍需包含这些预测 [9]。	讨论帖 “Inquiry Regarding the Exclusion of the Last 10 Timeids from Evaluation”
提交格式争议	多名选手讨论发现比赛说明中的示例容易误导，正确的 CSV 表头应为 `Uid,prediction` 而不是 `stockid|dateid|timeid,prediction` [10]。若表头错误，Kaggle 会报错 “Solution and submission values for Uid do not match”。	讨论帖 “正确格式应该是：Uid,prediction” 等
模型训练平台建议	数据集大约 45 GB，存储在 `train.parquet`，按 `stockid` 分区，主持人建议参赛者不必在内存中加载全部数据，可设计数据加载器按股票或批次读取，以降低存储压力 [11]。有参赛者抱怨下载数据较慢，建议将数据分块或改善下载渠道。	讨论帖 “Advice on where to train the model?”
评测指标解释	参赛者询问 R^2 计算方式，主办方答复使用 **面板 R^2**（一次性在整个测试集上计算），而不是每个截面平均的 R^2 [5]。	讨论帖 “Question About Evaluation”
避免未来信息的特征工程	有选手担心在特征工程时不慎泄露未来信息；主办方回复表示会通过审核提交代码判断是否使用未来特征，若发现违规将取消资格 [12]。其他选手提醒不要在特征中引入未来窗口或在滑动窗口中使用 t+1 等未来数据。	讨论帖 “如何在评测的时候避免未来函数”

总结

“China A-Share Market Microstructure Prediction” 是一项面向量化交易领域的挑战，参赛者需要利用 500 只 A 股的 Level 2 深度盘口数据建立短期收益预测模型。比赛数据体积庞大且特征维度高，要求参赛者设计合理的数据加载和模型训练方案。在提交结果时，需遵循正确的 CSV 格式（`Uid,prediction`），预测文件必须包含所有 `timeid`，即使最后 10 个 timeid 不计入评分。评测指标采用面板 R^2，通过整体样本评估预测质量。官方规则限制每天提交次数、团队规模，并要求获胜团队提交可复现的代码。讨论区的交流提醒参赛者谨慎使用特征工程，避免引入未来信息，否则将导致作品取消资格。

---

[1] [3] [4] China A-Share Market Microstructure Prediction | Kaggle
https://www.kaggle.com/competitions/china-a-share-market-microstructure-prediction

[2] China A-Share Market Microstructure Prediction | Kaggle
https://www.kaggle.com/competitions/china-a-share-market-microstructure-prediction/data

[5] China A-Share Market Microstructure Prediction | Kaggle
https://www.kaggle.com/competitions/china-a-share-market-microstructure-prediction/discussion/672170

[6] [7] China A-Share Market Microstructure Prediction | Kaggle
https://www.kaggle.com/competitions/china-a-share-market-microstructure-prediction/rules

[8] China A-Share Market Microstructure Prediction | Kaggle
https://www.kaggle.com/competitions/china-a-share-market-microstructure-prediction/discussion/672411

[9] China A-Share Market Microstructure Prediction | Kaggle
https://www.kaggle.com/competitions/china-a-share-market-microstructure-prediction/discussion/672887%233404732

[10] China A-Share Market Microstructure Prediction | Kaggle
https://www.kaggle.com/competitions/china-a-share-market-microstructure-prediction/discussion/673788

[11] China A-Share Market Microstructure Prediction | Kaggle
https://www.kaggle.com/competitions/china-a-share-market-microstructure-prediction/discussion/671696

[12] China A-Share Market Microstructure Prediction | Kaggle
https://www.kaggle.com/competitions/china-a-share-market-microstructure-prediction/discussion/680000